

Выявление мошенничества в транзакциях электронной коммерции

Ишкинин Даниэль



Анализ набора данных

Цель

- разработка и тестирование моделей МО для выявления мошенничества в транзакциях электронной коммерции
- исследовательский анализ данных
- разработка функций и тестирования алгоритмов выявления мошенничества

Способ генерации

- данные полностью синтетические
- сгенерированы с помощью Python Faker и пользовательской логики
- имитируют транзакции и мошеннические сценарии
- не основаны на реальных людях или операциях

Анализ набора данных

Признаки

Информация о транзакции

- Идентификатор транзакции
- Сумма транзакции
- Дата транзакции
- Время транзакции
- Способ оплаты
- Является ли транзакция мошеннической

Информация о продукте

- Категория продукта
- Количество продуктов

Информация о клиенте

- Идентификатор клиента
- Возраст клиента
- Местоположение клиента
- Возраст учетной записи в днях
- Адрес доставки
- Адрес для выставления счета

Техническая информация

- Используемое устройство
- IP-адрес

Анализ набора данных


Dataset

	Transaction ID	Customer ID	Transaction Amount	Transaction Date	Payment Method	Product Category	Quantity	Customer Age	Customer Location	Device Used	IP Address	Shipping Address	Billing Address	Is Fraudulent	Account Age Days	Transaction Hour
737256	3c343543-e215-41bf-9de0-d3f61288e853	c5f611c9-aef4-45b6-88b6-7037bac6e3dc	61.10	2024-02-16 08:52:05	bank transfer	health & beauty	4	37	Joanshire	desktop	193.252.95.175	724 Hutchinson Prairie\nAlexanderville, IA 02209	724 Hutchinson Prairie\nAlexanderville, IA 02209	0	85	8
195559	6bfd0f01-104c-4696-84fc-e892680a3ce5	ccf87796-f8bd-4636-ab12-2b01cb0dbb53	482.27	2024-02-11 13:28:11	bank transfer	health & beauty	4	34	Melindaburgh	mobile	31.62.187.239	6409 Watson Lock\nGillton, MI 19769	6409 Watson Lock\nGillton, MI 19769	0	146	13
254794	1044c3e8-8c46-4e2d-b925-0213c8a4a7ec	34b7b108-a0ac-47d5-9ea9-630e914739e1	134.03	2024-02-15 18:47:16	debit card	electronics	5	25	Royport	tablet	66.151.76.47	97378 Robert Crossing Apt. 451\nHancockcton, VA...	97378 Robert Crossing Apt. 451\nHancockcton, VA...	0	154	18
1099206	7b14600b-9cd3-4d67-8929-0b8f1b7c7f4f	d59ca70e-52f7-4e0d-8566-2503738f7a24	55.30	2024-03-08 21:14:47	credit card	health & beauty	2	36	Frostchester	mobile	126.125.67.197	29465 Frank Path Apt. 456\nNew April, VT 24735	29465 Frank Path Apt. 456\nNew April, VT 24735	0	143	21
879253	1ddd5c30-52b3-4961-8bc8-cf340675878f	738a3541-9aad-4522-9bc9-5fa509478cc3	23.88	2024-02-16 15:21:31	PayPal	clothing	4	30	South Amanda	tablet	150.201.64.50	Unit 4498 Box 9243\nDPO AA 85494	392 Vicki Summit Suite 765\nLake Brenda, SC 66347	0	116	15

Бизнес задача


Разработать модель машинного обучения для автоматического выявления мошеннических транзакций в электронной коммерции

Целевая переменная




мошенничество это или нет

Разделение данных




Анализ признаков



Распределение транзакций по типу




Распределение способов оплаты



Анализ признаков




Анализ признаков




Анализ признаков

Распределение сумм операций





Распределение количества товаров



Анализ признаков

Т.к. признак типа datetime не возможно использовать для обучения модели, выделим из столбца 'Transaction Date' производные потенциально полезные признаки: день недели и время транзакции (которое уже учтено в столбце 'Transaction Hour')



Анализ признаков

	Transaction ID	Customer ID	Customer Location	IP Address	Shipping Address	Billing Address
count	100000	100000	100000	100000	100000	100000
unique	100000	100000	38100	99997	100000	100000
top	3c343543-e215-41bf-9de0-d3f61288e853	c5f611c9-aef4-45b6-88b6-7037bac6e3dc	Lake Michael	173.59.19.127	724 Hutchinson Prairie\nAlexanderville, IA 02209	724 Hutchinson Prairie\nAlexanderville, IA 02209
freq	1	1	90	2	1	1

Признаки

- 'Transaction ID'
- 'Customer ID'
- 'IP Address'
- 'Shipping Address'
- 'Billing Address'

содержат только уникальные значения. Т.к. они не несут полезной информации для обучения модели, далее мы их не рассматривали

Признак 'Customer Location' возможно будет полезен при обучении

Обучение модели

1. На исходных данных

Разделив выборку на train и valid (20%), мы обучили модель CatBoostClassifier и на валидационных данных с порогом 0.5 получили следующие метрики

Precision: 0.79

Recall: 0.14




Диаграмма важности признаков, показывающая, что основной вклад вносят всего 3 признака

Обучение модели

2. Используя только время жизни аккаунта, время проведения транзакции и ее сумму

Метрики на валидации:

Precision = 0.8

Recall = 0.14

Оставим данные фичи, т.к. SMOTE корректно работает именно с числовыми признаками (не категориальными)

Метрики на тесте:

Precision = 0.78

Recall = 0.15

Применим SMOTE, т.к. в данных большой дисбаланс классов, что приводит к низкой полноте

Добавление синтетики

Метрики на валидации:

Precision = 0.81

Recall = 0.8

Полнота на валидации (содержащей синтетику) выросла, однако необходимо посмотреть на метрики на реальных данных (test)

Метрики на тесте:

Precision = 0.16

Recall = 0.64

Точность на тестовой выборке значительно снизилась, модель чаще ошибочно детектирует мошенничество. Возможно, это связано с малым числом исходных фрод-транзакций при SMOTE (увеличение в 19 раз) и их низким разнообразием, поскольку они уже были синтетическими

Балансировка классов в катбусте

Попробуем исправить дисбаланс классов в датасете встроенными методами катбуста

```
auto_class_weights='Balanced'
```

Нормализуем значения фичей

```
StandardScaler
```

Параметр **auto_class_weights='Balanced'** в CatBoost означает, что веса классов будут автоматически скорректированы пропорционально обратной частоте их встречаемости

- Это полезно при наличии дисбаланса классов, так как модель будет уделять больше внимания менее представленным классам

$$CW_k = \frac{\max_{c=1}^K (\sum_{t_i=c} w_i)}{\sum_{t_i=k} w_i}$$

StandardScaler из библиотеки `sklearn.preprocessing` стандартизирует числовые признаки путем вычитания среднего и деления на стандартное отклонение (z-score нормализация)

- Это приводит к тому, что все признаки имеют среднее 0 и стандартное отклонение 1, что помогает моделям лучше обучаться

Балансировка классов в катбусте

Метрики на валидации:

Precision = 0.14

Recall = 0.73

Результаты аналогичны SMOTE

Возможно, из-за синтетической природы исходного датасета, придание большей значимости классу 1 приводит к ухудшению метрик

Используем

sqrt-балансировку классов

т.к. она уменьшит различие между весами классов

auto_class_weights='SqrtBalanced' работает аналогично Balanced, но вместо прямой инверсии частот классов использует квадратный корень от обратной частоты

- Это менее агрессивный вариант балансировки, который сглаживает влияние редких классов

$$CW_k = \sqrt{\frac{\max_{c=1}^K (\sum_{t_i=c} w_i)}{\sum_{t_i=k} w_i}}$$

Балансировка классов в катбусте

Метрики на валидации:

Precision = 0.41


Recall = 0.4

Модель без балансировки весов

Метрики на валидации:

Precision = 0.8

Recall = 0.14





Подбор порогов

	threshold	precision	precision_sqrt	recall	recall_sqrt
0	0.50	0.78	0.42	0.15	0.41
1	0.55	0.83	0.43	0.14	0.39
2	0.60	0.85	0.44	0.14	0.38
3	0.65	0.85	0.47	0.13	0.31
4	0.70	0.89	0.57	0.12	0.22
5	0.75	0.93	0.65	0.10	0.18
6	0.80	0.96	0.73	0.09	0.16
7	0.85	0.97	0.83	0.08	0.14
8	0.90	0.98	0.91	0.07	0.11
9	0.95	1.00	0.98	0.06	0.08

Если в приоритете точность, стоит взять первую модель с порогом 0.75


Если в приоритете полнота, подойдет вторая модель с порогом 0.7

Подбор порогов




Прочие метрики

Precision-Recall Curve



ROC Curve



Спасибо за внимание!

Вопросы?

