

# Выявление мошенничества в транзакциях электронной коммерции

Ишкинин Даниэль



# Анализ набора данных

## Цель

- разработка и тестирование моделей МО для выявления мошенничества в транзакциях электронной коммерции
- исследовательский анализ данных
- разработка функций и тестирования алгоритмов выявления мошенничества

## Способ генерации

- данные полностью синтетические
- сгенерированы с помощью Python Faker и пользовательской логики
- имитируют транзакции и мошеннические сценарии
- не основаны на реальных людях или операциях

# Анализ набора данных

Признаки

## Информация о транзакции

- Идентификатор транзакции
- Сумма транзакции
- Дата транзакции
- Время транзакции
- Способ оплаты
- Является ли транзакция мошеннической

## Информация о продукте

- Категория продукта
- Количество продуктов

## Информация о клиенте

- Идентификатор клиента
- Возраст клиента
- Местоположение клиента
- Возраст учетной записи в днях
- Адрес доставки
- Адрес для выставления счета

## Техническая информация

- Используемое устройство
- IP-адрес

# Анализ набора данных


Dataset

|         | Transaction ID                       | Customer ID                          | Transaction Amount | Transaction Date    | Payment Method | Product Category | Quantity | Customer Age | Customer Location | Device Used | IP Address     | Shipping Address                                   | Billing Address                                    | Is Fraudulent | Account Age Days | Transaction Hour |
|---------|--------------------------------------|--------------------------------------|--------------------|---------------------|----------------|------------------|----------|--------------|-------------------|-------------|----------------|----------------------------------------------------|----------------------------------------------------|---------------|------------------|------------------|
| 737256  | 3c343543-e215-41bf-9de0-d3f61288e853 | c5f611c9-aef4-45b6-88b6-7037bac6e3dc | 61.10              | 2024-02-16 08:52:05 | bank transfer  | health & beauty  | 4        | 37           | Joanshire         | desktop     | 193.252.95.175 | 724 Hutchinson Prairie\nAlexanderville, IA 02209   | 724 Hutchinson Prairie\nAlexanderville, IA 02209   | 0             | 85               | 8                |
| 195559  | 6bfd0f01-104c-4696-84fc-e892680a3ce5 | ccf87796-f8bd-4636-ab12-2b01cb0dbb53 | 482.27             | 2024-02-11 13:28:11 | bank transfer  | health & beauty  | 4        | 34           | Melindaburgh      | mobile      | 31.62.187.239  | 6409 Watson Lock\nGillton, MI 19769                | 6409 Watson Lock\nGillton, MI 19769                | 0             | 146              | 13               |
| 254794  | 1044c3e8-8c46-4e2d-b925-0213c8a4a7ec | 34b7b108-a0ac-47d5-9ea9-630e914739e1 | 134.03             | 2024-02-15 18:47:16 | debit card     | electronics      | 5        | 25           | Royport           | tablet      | 66.151.76.47   | 97378 Robert Crossing Apt. 451\nHancockcton, VA... | 97378 Robert Crossing Apt. 451\nHancockcton, VA... | 0             | 154              | 18               |
| 1099206 | 7b14600b-9cd3-4d67-8929-0b8f1b7c7f4f | d59ca70e-52f7-4e0d-8566-2503738f7a24 | 55.30              | 2024-03-08 21:14:47 | credit card    | health & beauty  | 2        | 36           | Frostchester      | mobile      | 126.125.67.197 | 29465 Frank Path Apt. 456\nNew April, VT 24735     | 29465 Frank Path Apt. 456\nNew April, VT 24735     | 0             | 143              | 21               |
| 879253  | 1ddd5c30-52b3-4961-8bc8-cf340675878f | 738a3541-9aad-4522-9bc9-5fa509478cc3 | 23.88              | 2024-02-16 15:21:31 | PayPal         | clothing         | 4        | 30           | South Amanda      | tablet      | 150.201.64.50  | Unit 4498 Box 9243\nDPO AA 85494                   | 392 Vicki Summit Suite 765\nLake Brenda, SC 66347  | 0             | 116              | 15               |

# Бизнес задача


Разработать модель машинного обучения для автоматического выявления мошеннических транзакций в электронной коммерции

# Целевая переменная




мошенничество это или нет

# Разделение данных




# Анализ признаков



Распределение транзакций по типу



Распределение способов оплаты




# Анализ признаков






# Анализ признаков




# Анализ признаков

Распределение сумм операций





Распределение количества товаров



# Анализ признаков

Т.к. признак типа datetime не возможно использовать для обучения модели, выделим из столбца 'Transaction Date' производные потенциально полезные признаки: день недели и время транзакции (которое уже учтено в столбце 'Transaction Hour')



# Анализ признаков

|        | Transaction ID                       | Customer ID                          | Customer Location | IP Address    | Shipping Address                                    | Billing Address                                     |
|--------|--------------------------------------|--------------------------------------|-------------------|---------------|-----------------------------------------------------|-----------------------------------------------------|
| count  | 100000                               | 100000                               | 100000            | 100000        | 100000                                              | 100000                                              |
| unique | 100000                               | 100000                               | 38100             | 99997         | 100000                                              | 100000                                              |
| top    | 3c343543-e215-41bf-9de0-d3f61288e853 | c5f611c9-aef4-45b6-88b6-7037bac6e3dc | Lake Michael      | 173.59.19.127 | 724 Hutchinson<br>Prairie\nAlexanderville, IA 02209 | 724 Hutchinson<br>Prairie\nAlexanderville, IA 02209 |
| freq   | 1                                    | 1                                    | 90                | 2             | 1                                                   | 1                                                   |

## Признаки

- 'Transaction ID'
- 'Customer ID'
- 'IP Address'
- 'Shipping Address'
- 'Billing Address'

содержат только уникальные значения. Т.к. они не несут полезной информации для обучения модели, далее мы их не рассматривали

Признак 'Customer Location' возможно будет полезен при обучении

# Обучение модели

## 1. На исходных данных

Разделив выборку на train и valid (20%), мы обучили модель CatBoostClassifier и на валидационных данных с порогом 0.5 получили следующие метрики

Precision: 0.79

Recall: 0.14




Диаграмма важности признаков, показывающая, что основной вклад вносят всего 3 признака

# Обучение модели

2. Используя только время жизни аккаунта, время проведения транзакции и ее сумму

## Метрики на валидации:

Precision = 0.8

Recall = 0.14

Оставим данные фичи, т.к. SMOTE корректно работает именно с числовыми признаками (не категориальными)

## Метрики на тесте:

Precision = 0.78

Recall = 0.15

Применим SMOTE, т.к. в данных большой дисбаланс классов, что приводит к низкой полноте

# Добавление синтетики

## Метрики на валидации:

Precision = 0.81

Recall = 0.8

Полнота на валидации (содержащей синтетику) выросла, однако необходимо посмотреть на метрики на реальных данных (test)

## Метрики на тесте:

Precision = 0.16

Recall = 0.64

Точность на тестовой выборке значительно снизилась, модель чаще ошибочно детектирует мошенничество. Возможно, это связано с малым числом исходных фрод-транзакций при SMOTE (увеличение в 19 раз) и их низким разнообразием, поскольку они уже были синтетическими

# Балансировка классов в катбусте

Попробуем исправить дисбаланс классов в датасете встроенными методами катбуста

```
auto_class_weights='Balanced'
```

Нормализуем значения фичей

```
StandardScaler
```

Параметр **auto\_class\_weights='Balanced'** в CatBoost означает, что веса классов будут автоматически скорректированы пропорционально обратной частоте их встречаемости

- Это полезно при наличии дисбаланса классов, так как модель будет уделять больше внимания менее представленным классам

$$CW_k = \frac{\max_{c=1}^K (\sum_{t_i=c} w_i)}{\sum_{t_i=k} w_i}$$

**StandardScaler** из библиотеки `sklearn.preprocessing` стандартизирует числовые признаки путем вычитания среднего и деления на стандартное отклонение (z-score нормализация)

- Это приводит к тому, что все признаки имеют среднее 0 и стандартное отклонение 1, что помогает моделям лучше обучаться



# Балансировка классов в катбусте

## Метрики на валидации:

Precision = 0.14

Recall = 0.73

Результаты аналогичны SMOTE

Возможно, из-за синтетической природы исходного датасета, придание большей значимости классу 1 приводит к ухудшению метрик

Используем

sqrt-балансировку классов

т.к. она уменьшит различие между весами классов

auto\_class\_weights='SqrtBalanced' работает аналогично Balanced, но вместо прямой инверсии частот классов использует квадратный корень от обратной частоты

- Это менее агрессивный вариант балансировки, который сглаживает влияние редких классов

$$CW_k = \sqrt{\frac{\max_{c=1}^K (\sum_{t_i=c} w_i)}{\sum_{t_i=k} w_i}}$$

## Балансировка классов в катбусте

### Метрики на валидации:

Precision = 0.41


Recall = 0.4

## Модель без балансировки весов

### Метрики на валидации:

Precision = 0.8

Recall = 0.14





# Подбор порогов

|   | threshold | precision | precision_sqrt | recall | recall_sqrt |
|---|-----------|-----------|----------------|--------|-------------|
| 0 | 0.50      | 0.78      | 0.42           | 0.15   | 0.41        |
| 1 | 0.55      | 0.83      | 0.43           | 0.14   | 0.39        |
| 2 | 0.60      | 0.85      | 0.44           | 0.14   | 0.38        |
| 3 | 0.65      | 0.85      | 0.47           | 0.13   | 0.31        |
| 4 | 0.70      | 0.89      | 0.57           | 0.12   | 0.22        |
| 5 | 0.75      | 0.93      | 0.65           | 0.10   | 0.18        |
| 6 | 0.80      | 0.96      | 0.73           | 0.09   | 0.16        |
| 7 | 0.85      | 0.97      | 0.83           | 0.08   | 0.14        |
| 8 | 0.90      | 0.98      | 0.91           | 0.07   | 0.11        |
| 9 | 0.95      | 1.00      | 0.98           | 0.06   | 0.08        |

Если в приоритете точность, стоит взять первую модель с порогом 0.75


Если в приоритете полнота, подойдет вторая модель с порогом 0.7

# Подбор порогов




# Прочие метрики

Precision-Recall Curve



ROC Curve



# Спасибо за внимание!

Вопросы?

